

PROYECTO FINAL

Big Data y Analítica para Retail de Moda

JUAN DAVID PIEDRAHITA ESPINOZA
SARA ALEXANDRA MONSALVE CARDONA
JESICA MARIA FONNEGRA TARAZONA

Mayo 22 del 2026

1 Caso de Negocio

El proyecto desarrolla una solución analítica de Big Data aplicada al sector Retail de Moda mediante una arquitectura Medallion implementada en Databricks. El desafío principal consiste en transformar grandes volúmenes de datos de ventas, categorías, temporadas, márgenes y preferencias del consumidor en información estratégica para la toma de decisiones empresariales.

La solución propuesta permite identificar patrones de rotación de prendas, comportamiento estacional, segmentos de precio, márgenes de rentabilidad y preferencias del consumidor, generando ventajas competitivas para la organización.

1.1 Objetivos del Proyecto

- Implementar una arquitectura Medallion (Bronze, Silver y Gold) para garantizar calidad y trazabilidad de datos.
- Automatizar la ingesta y transformación de datos en Databricks.
- Construir dashboards ejecutivos interactivos para la toma de decisiones.
- Identificar categorías y temporadas con mayor rentabilidad.
- Optimizar estrategias comerciales mediante analítica descriptiva.

2 Relación Beneficio / Coste

La implementación de la solución reduce tiempos operativos relacionados con consolidación manual de información, análisis comerciales y generación de reportes ejecutivos.

2.1 Análisis Económico

- Reducción estimada del 60% en horas-hombre destinadas a consolidación de reportes.
- Centralización de datos mediante Delta Lake y Databricks.
- Disminución de errores manuales en procesos de análisis.
- Automatización de pipelines y dashboards ejecutivos.

2.2 Retorno de Inversión

La solución genera valor mediante:

- Incremento en ventas por mejor entendimiento del comportamiento del cliente.
- Optimización de inventarios estacionales.
- Identificación de categorías de alta rentabilidad.
- Reducción de costos operativos y analíticos.

3 Arquitectura Propuesta

La arquitectura implementada sigue el modelo Medallion dentro de Databricks:

- **Bronze:** almacenamiento de datos crudos provenientes del dataset.
- **Silver:** limpieza, validación, enriquecimiento y feature engineering.
- **Gold:** tablas analíticas orientadas al negocio y dashboards.

La solución utiliza Spark, Delta Lake, Pandas, Plotly y SQL Analytics.

4 Pipeline de Ingesta de Datos

4.1 Automatización de Ingesta

El notebook principal automatiza:

- Generación/carga del dataset.
- Conversión a Spark DataFrame.
- Persistencia en Delta Lake.
- Validación de calidad.
- Transformaciones analíticas.

4.2 Estrategia Medallion

4.2.1 Bronze

Se realiza la ingestión de datos crudos manteniendo la estructura original para trazabilidad y auditoría.

4.2.2 Silver

Se ejecutan procesos de limpieza, eliminación de duplicados, validaciones de negocio y creación de variables derivadas como:

- gross_margin
- total_revenue
- total_gross_profit
- price_tier
- rating_tier

4.2.3 Gold

Se construyen KPIs ejecutivos y tablas analíticas:

- Rotación por categoría y temporada
- Revenue mensual
- Preferencias del consumidor
- Relación precio vs margen
- Performance de marcas

5 Modelos de Ciencia de Datos

5.1 Análisis Descriptivo

Los principales hallazgos incluyen:

- Mayor revenue en temporadas Summer y Autumn.
- Segmentos Premium y Mid-Range generan mayor utilidad.
- Categorías Jeans y Dress presentan alta rotación.
- Colores oscuros muestran mayor preferencia de compra.

5.2 KPIs Ejecutivos

Indicador	Valor
Revenue Total	\$18.5M USD
Ganancia Bruta	\$9.1M USD
Margen Promedio	49.8%
Unidades Vendidas	$\approx$ 430,000
Categoría Líder	Jeans
Estación Líder	Summer

6 Visualización y Dashboard

El dashboard ejecutivo fue construido en Databricks Lakeview utilizando múltiples datasets analíticos.

Datasets identificados:

- Price Tier Analysis
- Season Category Metrics
- Monthly Trends
- Color Preferences
- Gender Segment Analysis
- Brand Performance
- Category Profit
- Category Rating
- Quarterly Units
- Price vs Margin Scatter

Principales widgets visuales:

- Unidades por Categoría y Temporada
- Tendencia Mensual de Ingresos
- Colores Más Vendidos
- Ingresos por Categoría y Temporada
- Precio vs Margen
- Ingresos por Tier y Temporada

- Ingresos por Género y Tier
- Marcas Líderes
- Top Categorías por Utilidad Bruta
- Categorías por Calificación Promedio




Figure 1: Top categorías por ingresos




Figure 2: Precio vs Margen

7 Conclusiones

La implementación de la arquitectura Medallion en Databricks permitió consolidar una plataforma robusta de análisis de datos para Retail de Moda. El proyecto demuestra cómo Big Data y analítica avanzada facilitan decisiones comerciales estratégicas basadas en evidencia, optimizando rentabilidad, rotación de inventario y experiencia del cliente.

8 Dashboard Ejecutivo Completo

Las siguientes visualizaciones corresponden directamente a los widgets implementados en el Dashboard Ejecutivo desarrollado en Databricks Lakeview. Estas gráficas permiten analizar tendencias de ingresos, comportamiento estacional, rentabilidad, segmentos de precio, preferencias del consumidor y desempeño comercial de las categorías del Retail de Moda.




Figure 3: Categorías por Calificación Promedio

La visualización evidencia que las categorías del portafolio presentan una calificación promedio relativamente homogénea, cercana al valor máximo de satisfacción del cliente. Sin embargo, categorías como Blouse y Hoodie muestran una ligera ventaja sobre las demás.

Desde la perspectiva analítica, este comportamiento indica estabilidad en la percepción de calidad de los productos, lo cual representa un indicador positivo para la estrategia comercial de la marca. La ausencia de diferencias drásticas entre categorías sugiere que el nivel de experiencia del cliente es consistente a lo largo del portafolio.

Adicionalmente, las categorías con mayores ingresos como Jeans y Dress mantienen calificaciones competitivas, demostrando que el volumen de ventas no está sacrificando la satisfacción del consumidor. Esto favorece estrategias de fidelización y recompra.




Figure 4: Colores Más Vendidos

La gráfica muestra que los colores Blue y Navy concentran el mayor volumen de ventas, seguidos por Green y Brown. Los colores neutros y oscuros mantienen una participación dominante dentro de las preferencias de compra.

Este patrón confirma una tendencia típica en el retail de moda: los consumidores priorizan colores versátiles y de fácil combinación, especialmente en categorías de uso frecuente. Desde el punto de vista de negocio, esta información es altamente relevante para:

Planeación de inventario. Pronóstico de demanda. Estrategias de abastecimiento. Diseño de nuevas colecciones.

Los resultados permiten concluir que existe una fuerte oportunidad de optimizar el inventario priorizando tonalidades de alta rotación y reduciendo sobre costos asociados a colores de menor demanda.




Figure 5: Ingresos por Categoría y Temporada

La visualización evidencia una clara estacionalidad en el comportamiento de ingresos. La categoría Coat presenta un desempeño sobresaliente durante la temporada Winter, mientras que categorías como Dress y Jeans mantienen un comportamiento más equilibrado entre temporadas.

Desde el análisis comercial, esto demuestra que algunas categorías dependen fuertemente de factores climáticos y de temporalidad, mientras otras poseen demanda relativamente constante.

Los hallazgos permiten identificar tres comportamientos clave:

Productos altamente estacionales (Coat). Productos de rotación continua (Jeans). Productos sensibles a tendencias de temporada (Dress).

Esta segmentación es fundamental para optimizar estrategias de inventario y campañas promocionales según el calendario comercial.



Figure 6: Ingresos por Genero y Tier

La gráfica indica que el segmento Premium representa la mayor proporción de ingresos para todos los géneros (Female, Male y Unisex), seguido por el segmento Mid-Range.

El hallazgo demuestra que los consumidores están dispuestos a pagar precios superiores cuando perciben mayor valor en los productos. Además, el comportamiento homogéneo entre géneros indica que el posicionamiento de marca premium tiene aceptación transversal.

Desde una perspectiva estratégica:

El segmento Premium se consolida como principal motor de rentabilidad. El segmento Budget aporta menor participación en revenue. El segmento Unisex presenta una oportunidad importante de crecimiento debido a su estabilidad comercial.

La empresa podría fortalecer campañas diferenciadas para productos premium y aumentar márgenes mediante estrategias de valor agregado.




Figure 7: Ingresos por Tier y Temporada

La figura evidencia que el segmento Premium alcanza sus mayores ingresos durante Winter, mientras que el segmento Mid-Range presenta alto desempeño en Summer.

Este comportamiento confirma que los hábitos de consumo cambian según la temporada y el nivel de precio del producto. Durante temporadas frías, los consumidores tienden a adquirir productos de mayor valor agregado, posiblemente relacionados con prendas más costosas como abrigos o chaquetas.

El análisis permite concluir que:

Las estrategias comerciales deben adaptarse dinámicamente por temporada. El segmento Luxury tiene un comportamiento más volátil. Mid-Range mantiene estabilidad durante todo el año.

Esta información es clave para definir campañas estacionales y distribución eficiente del presupuesto comercial.




Figure 8: Marcas Líderes

La gráfica posiciona a Uniqlo y Levi's como las marcas con mayor revenue acumulado, seguidas por PullBear, HM y Tommy Hilfiger.

El resultado sugiere que las marcas líderes combinan:

Alto reconocimiento. Amplia rotación. Capacidad de adaptación a múltiples segmentos de precio.

Particularmente, Levi's mantiene coherencia con el liderazgo de la categoría Jeans, evidenciando una fuerte correlación entre marca y categoría dominante.

Desde la analítica comercial, esta visualización permite:

Identificar marcas estratégicas para alianzas. Priorizar negociaciones con proveedores líderes. Diseñar campañas enfocadas en marcas de alto rendimiento.



Figure 9: precio vs margen

La dispersión muestra una relación inversa moderada entre el precio de venta y el margen bruto. Los productos Budget y Mid-Range concentran márgenes más altos y consistentes, mientras los productos Luxury presentan precios elevados con márgenes relativamente menores.

Este comportamiento sugiere que los productos de lujo requieren mayores costos operativos, logísticos o de fabricación, reduciendo el margen relativo pese a sus altos precios.

Analíticamente, la figura demuestra:

El segmento Mid-Range ofrece un equilibrio óptimo entre volumen y rentabilidad. El segmento Premium mantiene buena estabilidad comercial. Los productos Luxury podrían requerir revisión de costos o estrategia de pricing.

La dispersión también evidencia oportunidades para modelos predictivos de rentabilidad basados en elasticidad precio-margen.




Figure 10: revenue categoria estacion

La matriz térmica evidencia que:

Coat domina ampliamente en Winter. Dress y Jeans presentan ingresos altos y constantes. Algunas categorías menores muestran dependencia extrema de una única temporada.

La intensidad de color facilita identificar categorías estratégicas de alta rentabilidad estacional.

Desde el enfoque de ciencia de datos, esta visualización permite:

Detectar patrones estacionales. Construir modelos de forecasting. Optimizar abastecimiento por trimestre. Reducir riesgo de sobreinventario.

El análisis confirma que el comportamiento comercial del retail moda depende fuertemente de ciclos estacionales y preferencias temporales del consumidor.




Figure 11: tendencia ingresos

La tendencia mensual muestra que la temporada Winter mantiene el mayor nivel de ingresos durante gran parte del período analizado, aunque presenta una leve desaceleración progresiva.

Por otro lado:

Autumn mantiene estabilidad moderada. Summer presenta crecimiento gradual. Spring permanece como la temporada de menor revenue.

Esto permite identificar cambios progresivos en la demanda y posibles variaciones en preferencias de consumo.

Desde una perspectiva analítica, la estabilidad de las curvas refleja consistencia operativa y comportamiento relativamente predecible del negocio, lo cual favorece la construcción de modelos de proyección de ventas.




Figure 12: top utilidad bruta

La categoría Coat lidera claramente la utilidad bruta, seguida por Jacket y Blazer.

Aunque algunas categorías no lideran en volumen de ventas, sí presentan alta rentabilidad unitaria, lo cual es un hallazgo crítico para la estrategia financiera.

Esto indica que:

No siempre las categorías más vendidas son las más rentables. Productos de mayor ticket generan mejores márgenes absolutos. Existe potencial de crecimiento en categorías premium.

La empresa podría fortalecer campañas enfocadas en productos de alta utilidad para maximizar el EBITDA comercial.




Figure 13: unidades categoria temporada

La gráfica confirma nuevamente el fuerte componente estacional del retail de moda.

Se observa que:

T-Shirts y Shorts incrementan considerablemente sus unidades durante Summer. Coat y Jacket crecen durante Winter. Jeans mantiene estabilidad transversal.

Este comportamiento es coherente con patrones de consumo estacionales y permite diseñar estrategias de rotación de inventario mucho más eficientes.

Desde el análisis de datos, esta visualización es especialmente útil para:

Planeación logística. Gestión de inventario. Optimización de compras.




Figure 14: unidades trimestre

La visualización trimestral evidencia picos recurrentes de ventas durante los terceros trimestres (Q3), mientras los primeros trimestres presentan menor volumen relativo.

Este patrón puede estar asociado a:

Temporadas altas comerciales. Lanzamiento de colecciones. Incremento del consumo previo a temporadas festivas.

La estabilidad general entre períodos refleja una operación comercial madura y consistente.

Desde la analítica empresarial, esta información permite:

Anticipar necesidades de abastecimiento. Ajustar capacidad logística. Optimizar campañas comerciales trimestrales. Proyectar ingresos futuros con menor incertidumbre.

9 Conclusiones Finales

La consolidación del Dashboard Ejecutivo dentro del documento académico fortalece la evidencia analítica y técnica del proyecto. La integración de la arquitectura Medallion, los procesos ETL implementados en Databricks y las visualizaciones avanzadas permiten soportar decisiones estratégicas en Retail de Moda basadas en datos masivos y analítica avanzada.

Los resultados obtenidos permiten identificar patrones de comportamiento comercial, temporadas de mayor rentabilidad, segmentos de precio más competitivos y preferencias relevantes de los consumidores.

Los principales hallazgos indican:

Alta influencia de la estacionalidad sobre ingresos y unidades vendidas. Liderazgo consistente de categorías como Jeans, Coat y Dress. Mayor rentabilidad en segmentos Premium y Mid-Range. Preferencia marcada por colores neutros y oscuros. Oportunidades de optimización en gestión de inventario.