

# PROYECTO FINAL

## Big Data y Analítica para Retail de Moda

JUAN DAVID PIEDRAHITA ESPINOZA  
SARA ALEXANDRA MONSALVE CARDONA  
JESICA MARIA FONNEGRA TARAZONA

Mayo 22 del 2026

## 1 Caso de Negocio

El proyecto desarrolla una solución analítica de Big Data aplicada al sector Retail de Moda mediante una arquitectura Medallion implementada en Databricks. El desafío principal consiste en transformar grandes volúmenes de datos de ventas, categorías, temporadas, márgenes y preferencias del consumidor en información estratégica para la toma de decisiones empresariales.

La solución propuesta permite identificar patrones de rotación de prendas, comportamiento estacional, segmentos de precio, márgenes de rentabilidad y preferencias del consumidor, generando ventajas competitivas para la organización.

### 1.1 Objetivos del Proyecto

- Implementar una arquitectura Medallion (Bronze, Silver y Gold) para garantizar calidad y trazabilidad de datos.
- Automatizar la ingesta y transformación de datos en Databricks.
- Construir dashboards ejecutivos interactivos para la toma de decisiones.
- Identificar categorías y temporadas con mayor rentabilidad.
- Optimizar estrategias comerciales mediante analítica descriptiva.

## 2 Relación Beneficio / Coste

La implementación de la solución reduce tiempos operativos relacionados con consolidación manual de información, análisis comerciales y generación de reportes ejecutivos.

## 2.1 Análisis Económico

- Reducción estimada del 60% en horas-hombre destinadas a consolidación de reportes.
- Centralización de datos mediante Delta Lake y Databricks.
- Disminución de errores manuales en procesos de análisis.
- Automatización de pipelines y dashboards ejecutivos.

## 2.2 Retorno de Inversión

La solución genera valor mediante:

- Incremento en ventas por mejor entendimiento del comportamiento del cliente.
- Optimización de inventarios estacionales.
- Identificación de categorías de alta rentabilidad.
- Reducción de costos operativos y analíticos.

# 3 Arquitectura Propuesta

La arquitectura implementada sigue el modelo Medallion dentro de Databricks:

- **Bronze:** almacenamiento de datos crudos provenientes del dataset.
- **Silver:** limpieza, validación, enriquecimiento y feature engineering.
- **Gold:** tablas analíticas orientadas al negocio y dashboards.

La solución utiliza Spark, Delta Lake, Pandas, Plotly y SQL Analytics.

# 4 Pipeline de Ingesta de Datos

## 4.1 Automatización de Ingesta

El notebook principal automatiza:

- Generación/carga del dataset.
- Conversión a Spark DataFrame.
- Persistencia en Delta Lake.
- Validación de calidad.
- Transformaciones analíticas.

## 4.2 Estrategia Medallion

### 4.2.1 Bronze

Se realiza la ingestión de datos crudos manteniendo la estructura original para trazabilidad y auditoría.

### 4.2.2 Silver

Se ejecutan procesos de limpieza, eliminación de duplicados, validaciones de negocio y creación de variables derivadas como:

- gross\_margin
- total\_revenue
- total\_gross\_profit
- price\_tier
- rating\_tier

### 4.2.3 Gold

Se construyen KPIs ejecutivos y tablas analíticas:

- Rotación por categoría y temporada
- Revenue mensual
- Preferencias del consumidor
- Relación precio vs margen
- Performance de marcas

## 5 Modelos de Ciencia de Datos

### 5.1 Análisis Descriptivo

Los principales hallazgos incluyen:

- Mayor revenue en temporadas Summer y Autumn.
- Segmentos Premium y Mid-Range generan mayor utilidad.
- Categorías Jeans y Dress presentan alta rotación.
- Colores oscuros muestran mayor preferencia de compra.

## 5.2 KPIs Ejecutivos

| Indicador         | Valor             |
|-------------------|-------------------|
| Revenue Total     | \$18.5M USD       |
| Ganancia Bruta    | \$9.1M USD        |
| Margen Promedio   | 49.8%             |
| Unidades Vendidas | $\approx$ 430,000 |
| Categoría Líder   | Jeans             |
| Estación Líder    | Summer            |

## 6 Visualización y Dashboard

El dashboard ejecutivo fue construido en Databricks Lakeview utilizando múltiples datasets analíticos.

Datasets identificados:

- Price Tier Analysis
- Season Category Metrics
- Monthly Trends
- Color Preferences
- Gender Segment Analysis
- Brand Performance
- Category Profit
- Category Rating
- Quarterly Units
- Price vs Margin Scatter

Principales widgets visuales:

- Unidades por Categoría y Temporada
- Tendencia Mensual de Ingresos
- Colores Más Vendidos
- Ingresos por Categoría y Temporada
- Precio vs Margen
- Ingresos por Tier y Temporada

- Ingresos por Género y Tier
- Marcas Líderes
- Top Categorías por Utilidad Bruta
- Categorías por Calificación Promedio




Figure 1: Top categorías por ingresos




Figure 2: Precio vs Margen

## 7 Conclusiones

La implementación de la arquitectura Medallion en Databricks permitió consolidar una plataforma robusta de análisis de datos para Retail de Moda. El proyecto demuestra cómo Big Data y analítica avanzada facilitan decisiones comerciales estratégicas basadas en evidencia, optimizando rentabilidad, rotación de inventario y experiencia del cliente.

## 8 Dashboard Ejecutivo Completo

Las siguientes visualizaciones corresponden directamente a los widgets implementados en el Dashboard Ejecutivo desarrollado en Databricks Lakeview. Estas gráficas permiten analizar tendencias de ingresos, comportamiento estacional, rentabilidad, segmentos de precio, preferencias del consumidor y desempeño comercial de las categorías del Retail de Moda.




Figure 3: Categorías por Calificación Promedio




Figure 4: Colores Más Vendidos




Figure 5: Ingresos por Categoría y Temporada



Figure 6: Ingresos por Genero y Tier




Figure 7: Ingresos por Tier y Temporada




Figure 8: Marcas Líderes





Figure 9: precio vs margen




Figure 10: revenue categoria estacion




Figure 11: tendencia ingresos




Figure 12: top utilidad bruta




Figure 13: unidades categoria temporada




Figure 14: unidades trimestre

## 9 Conclusiones Finales

La consolidación del Dashboard Ejecutivo dentro del documento académico fortalece la evidencia analítica y técnica del proyecto. La integración de la arquitectura Medallion, los procesos ETL implementados en Databricks y las visualizaciones avanzadas permiten soportar decisiones estratégicas en Retail de Moda basadas en datos masivos y analítica avanzada.

Los resultados obtenidos permiten identificar patrones de comportamiento comercial, temporadas de mayor rentabilidad, segmentos de precio más competitivos y preferencias relevantes de los consumidores.